Introduction aux formats de fichiers et algorithmes utilis?s dans le TP2

November 22, 2018

1 Formats de fichiers

1.1 FASTA

Le fichier FASTA contient des séquences identifiées et annotés brièvement par une description.

```
>ID DESCRIPTION SEQUENCE
```

>NM_001025782.2 Caenorhabditis elegans Phosphatidylinositol 3-kinase catalytic subunit type 3

 ${\tt ATGCGAGTCTCCACGTCAGTCAACGGTGTTTGGGATTTTTCGGCCTGTACCCGTTACTGTGTAGCTGATCCTGAACT}$

```
In [3]: def read_fasta(path):
    with gzip.open(path, 'rt') as f:
        accession, description, seq = None, None, None
    for line in f:
        if line[0] == '>':
            # yield current record
            if accession is not None:
                 yield accession, description, seq

# start a new record
        accession, description = line[1:].rstrip().split(maxsplit=1)
            seq = ''
        else:
        seq += line.rstrip()
```

```
In [4]: next(read_fasta('GCF_000002985.6_WBcel235_rna.fna.gz'))
Out[4]: ('NM_001025782.2',
      'Caenorhabditis elegans Phosphatidylinositol 3-kinase catalytic subunit type 3 (vps-3-
       1.2 FASTQ
Le format FASTQ contient des fragments annotés avec une qualité pour chaque symboles lus par
le système de séquençage.
@SEQID DESCRIPTION
SEQUENCE
QUALITY
In [5]: with gzip.open('reads.fastq.gz', 'rt') as f:
        print(f.readline())
        print(f.readline())
        print(f.readline())
        print(f.readline())
@VOGKRUTI 1:11:1
```

1.3 BED

Le format BED est un format tabulaire de 3 à 12 colonnes qui contient des annotations de sousséquences.

```
reference start end name
```

Dans ce TP, nous utiliserons seulement les 4 premières colonnes pour identifier la référence, une paire de coordonnées (début, fin) et l'identifiant du contig assemblé depuis notre graphe de Brujin.

2 Notions de base et algorithmes

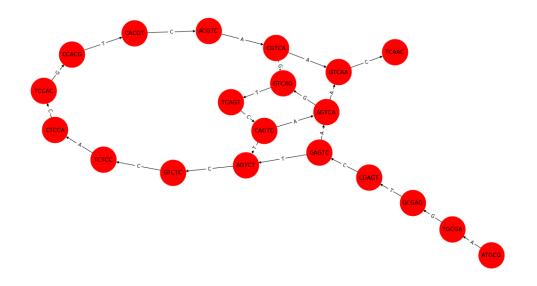
3 *k*-mer

Sous-séquence de longueur k. Une chaîne de longueur l possède l-k+1 k-mers.

4 Graphe de Brujin

Les sommets sont les *k*-mers et les arcs sont les transition sur un symbole de l'aphabet.

```
In [13]: k = 7
                         kmers = [seq[i:i+k] for i in range(1 - k + 1)]
                         def edges(kmers_graph):
                                     for k in kmers_graph:
                                                 for s in 'ATCG':
                                                             successor = k[1:] + s
                                                             if successor in kmers_graph:
                                                                        yield k, successor
                         for v1, v2 in islice(edges(set(kmers[:10])), 10):
                                     print(v1, v2, 'transition on {}'.format(v2[-1]))
TGCGAGT GCGAGTC transition on C
CGAGTCT GAGTCTC transition on C
CTCCACG TCCACGT transition on T
ATGCGAG TGCGAGT transition on T
GAGTCTC AGTCTCC transition on C
TCTCCAC CTCCACG transition on G
GTCTCCA TCTCCAC transition on C
AGTCTCC GTCTCCA transition on A
GCGAGTC CGAGTCT transition on T
In [14]: import networkx as nx
                         %matplotlib inline
                          import matplotlib.pyplot as plt
                         k = 5
                         kmers = [seq[i:i+k] for i in range(1 - k + 1)]
                         plt.figure(figsize=(16,8))
                         g = nx.DiGraph()
                         g.add_nodes_from(set(kmers[:20]))
                         g.add_edges_from((u, v, {'label': v[-1]}) for u, v in edges(set(kmers[:20])))
                         nx.draw(g, pos=nx.drawing.nx_agraph.graphviz_layout(g), with_labels=True, node_size=3
                         nx.draw_networkx_edge_labels(g, pos=nx.drawing.nx_agraph.graphviz_layout(g), edge_labels(g, pos=nx.drawing.nx_agraphviz_layout(g), edge_labels(g, pos=nx.dra
                         plt.show()
```



5 k-mer walk

Lorsque vous traverserez votre graphe, vous devrez adapter cette technique puisqu'il pourra exister plusieurs candidats potentiels et il sera également possible de revenir sur ses pas (i.e. une boucle).

```
In [15]: def kmer_walk(kmer_graph, start):
             k = start
             # yield the starting node
             yield k
             while True:
                 for symbol in ['A', 'T', 'C', 'G']:
                     candidate = k[1:] + symbol
                     if candidate in kmer_graph:
                         k = candidate
                         yield k
                         break
                 else:
                     break # break the while-loop if no more candidate is found
In [16]: k = 21
         kmers = [seq[i:i+k] for i in range(1 - k + 1)]
         kmer_graph = set(kmers)
         contig = None
```

```
for k in islice(kmer_walk(kmer_graph, start='GATGCATTAGAATTACTTTCA'), 20):
             if contig is None:
                 contig = k
             else:
                 contig += k[-1]
             print(((len(contig) - len(k)) * ' ') + k)
         print(contig)
GATGCATTAGAATTACTTTCA
 ATGCATTAGAATTACTTTCAA
  TGCATTAGAATTACTTTCAAG
  GCATTAGAATTACTTTCAAGT
    CATTAGAATTACTTTCAAGTG
     ATTAGAATTACTTTCAAGTGC
      TTAGAATTACTTTCAAGTGCA
       TAGAATTACTTTCAAGTGCAT
        AGAATTACTTTCAAGTGCATT
         GAATTACTTTCAAGTGCATTC
          AATTACTTTCAAGTGCATTCA
           ATTACTTTCAAGTGCATTCAC
            TTACTTTCAAGTGCATTCACT
             TACTTTCAAGTGCATTCACTC
              ACTTTCAAGTGCATTCACTCA
               CTTTCAAGTGCATTCACTCAT
                TTTCAAGTGCATTCACTCATC
                 TTCAAGTGCATTCACTCATCC
                  TCAAGTGCATTCACTCATCCG
                   CAAGTGCATTCACTCATCCGG
GATGCATTAGAATTACTTTCAAGTGCATTCACTCATCCGG
```

6 Exemple de cycle

La solution générale pour un cycle est de mémoriser les endroits déjà visité du graphe et d'interrompre le parcours.

```
In [17]: k = 6
    kmers = [seq[i:i+k] for i in range(l - k + 1)]

contig = None
    closed = set()

for k in islice(kmer_walk(kmers, start='GATGCA'), 40):
    if contig is None:
        contig = k
    else:
        contig += k[-1]
```

```
print(((len(contig) - len(k)) * ' ') + k, 'already visited!' if k in closed else
             if k in closed:
                 break # stop traversal on repeat
             else:
                 closed.add(k)
         print(contig)
GATGCA
 ATGCAA
  TGCAAA
  GCAAAA
    CAAAAA
     TAAAAA
      AAAATA
       AAATAT
        AATATA
         ATATAC
          TATACA
           ATACAA
            TACAAA
             ACAAAA
              CAAAAA already visited!
GATGCAAAAATATACAAAAA
```

7 Produire des identifiants aléatoires